Instituto Politécnico Nacional

Unidad Profesional Interdisciplinaria en Ingeniería y Tecnologías Avanzadas

Ingeniería Telemática

Bases de Datos Distribuidas

Grupo 3TM2

Tarea No. 2

Integrantes:

Nieves Hernandez Efrain

Rodríguez Escalera Ricardo

Sánchez Lemus Ulises Mariano

BASES DE DATOS DISTRIBUIDAS

Las bases de datos distribuidas (BDD) representan una evolución de los sistemas tradicionales centralizados, permitiendo el almacenamiento y procesamiento de datos en múltiples sitios interconectados. Este enfoque responde a la necesidad de soportar aplicaciones modernas con alta demanda de disponibilidad, escalabilidad y tolerancia a fallos.

De acuerdo con Özsu y Valduriez (2011), una base de datos distribuida es una colección de múltiples bases de datos lógicamente relacionadas, distribuidas en una red de computadoras, que son gestionadas por un sistema de gestión de bases de datos distribuidas (DDBMS).

Arquitecturas para bases de datos distribuidas

La arquitectura de una BDD define la organización estructural del sistema, incluyendo:

- La distribución de datos.
- La comunicación entre nodos.
- El grado de autonomía de cada sitio.

Según Özsu y Valduriez (2011), las arquitecturas se caracterizan por tres dimensiones clave:

- Distribución

  Se refiere a cómo los datos están físicamente dispersos en múltiples sitios. La distribución puede ser:

  - Centralizada (sin distribución real).
  - Cliente-servidor.
  - Totalmente distribuida.

- Autonomía

  Indica el grado de independencia de cada nodo. Puede clasificarse en:

  - *Autonomía local:* cada sitio controla sus datos.
  - *Autonomía de ejecución:* capacidad de ejecutar operaciones independientemente.
  - *Autonomía de comunicación:* control sobre intercambio de información.

- Heterogeneidad

  Se refiere a las diferencias entre sistemas:

  - Modelos de datos.
  - Lenguajes de consulta.
  - Hardware y sistemas operativos.

Tipos de Arquitecturas

1. Arquitectura Cliente-Servidor

Es una de las más utilizadas. Los clientes envían solicitudes y los servidores procesan datos.

- Puede ser de dos capas o tres capas.
- Facilita la administración centralizada.

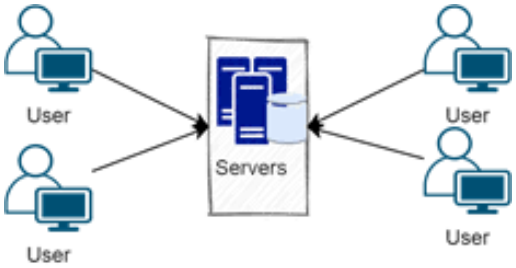

2. Arquitectura Distribuida Pura (Peer-to-Peer)

No existe un nodo central. Todos los nodos:

- Tienen las mismas capacidades
- Comparten responsabilidades

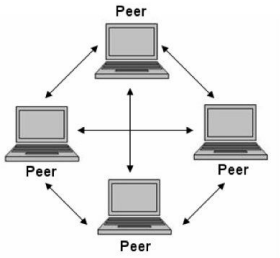

Este modelo mejora la escalabilidad, pero aumenta la complejidad del control.

3. Sistemas Multibase de Datos (MDBS)

Integran múltiples bases de datos autónomas.

Características:

- No existe un esquema global único completamente integrado
- Se mantiene la independencia de cada sistema

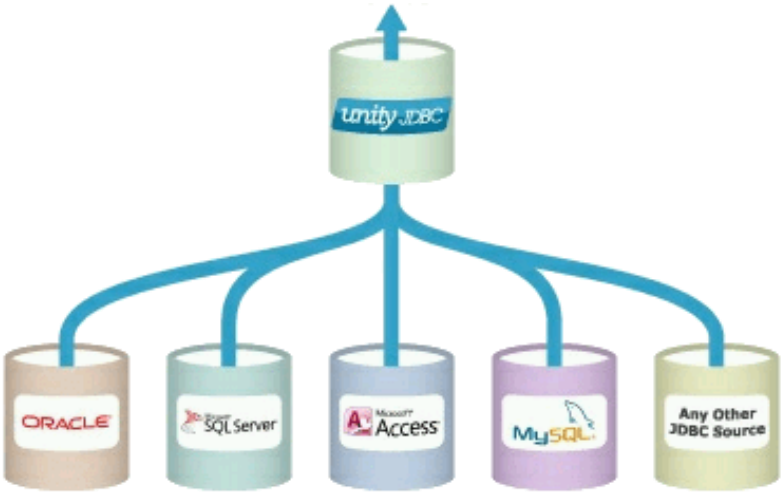

Transparencia en BDD

Un concepto central en el libro es la **transparencia de distribución**, que permite ocultar la complejidad al usuario.

Tipos principales:

- **Transparencia de localización:** el usuario no conoce dónde están los datos
- **Transparencia de fragmentación:** no se percibe la división de datos
- **Transparencia de replicación:** múltiples copias son invisibles al usuario

Según Özsu y Valduriez (2011), lograr transparencia total es uno de los principales objetivos de un DDBMS.

Gestores de bases de datos distribuidas

Un DDBMS es el software encargado de gestionar una base de datos distribuida, proporcionando una vista unificada de los datos. Su objetivo es que el sistema funcione como una base de datos centralizada, a pesar de su distribución física.

De acuerdo con el libro, un DDBMS debe:

- Gestionar consultas distribuidas
- Controlar la concurrencia
- Administrar transacciones distribuidas
- Garantizar recuperación ante fallos
- Mantener consistencia de datos

El sistema debe:

1. Descomponer la consulta
2. Determinar dónde están los datos
3. Optimizar la ejecución
4. Combinar resultados

Esto implica mayor complejidad que en sistemas centralizados.

	Fragmentación	Replicación
Definición	División de la base de datos en partes (fragmentos).	Copia de datos en múltiples nodos.
Objetivo principal	Mejorar rendimiento y acceso local.	Aumentar disponibilidad y tolerancia a fallos.
Tipos	• Horizontal: divide por filas. • Vertical: divide por columnas. • Mixta: combinación de ambas.	• Completa: todos los datos en todos los nodos. • Parcial: solo algunos fragmentos replicados.
Ubicación de datos	Cada fragmento en un nodo específico.	Múltiples copias en distintos nodos.
Acceso a datos	Se accede al fragmento correspondiente.	Se puede acceder a cualquier copia.
Consistencia	Más sencilla de mantener.	Más compleja (requiere sincronización).
Uso de almacenamiento	Eficiente (sin duplicación).	Alto (datos duplicados).
Rendimiento	Alto para consultas locales.	Alto para lecturas, puede afectar escrituras.
Tolerancia a fallos	Baja (si falla un nodo, se pierde ese fragmento).	Alta (existen copias de respaldo).
Reglas importantes	• Completitud: todos los datos deben estar en algún fragmento. • Reconstrucción: se debe poder reconstruir la relación original. • Disyunción: los fragmentos no deben solaparse (en fragmentación horizontal).	• Control de concurrencia. • Sincronización.
Ventajas	• Mejora el rendimiento. • Reduce tráfico de red. • Permite paralelismo	• Alta disponibilidad. • Tolerancia a fallos. • Mejora en tiempos de respuesta.
Ejemplo típico	Sharding en bases de datos.	Réplicas en sistemas distribuidos.

Las arquitecturas distribuidas permiten diseñar sistemas adaptados a distintos entornos, desde aplicaciones empresariales hasta sistemas globales.

El DDBMS desempeña un papel crítico al abstraer la complejidad de la distribución, permitiendo que los usuarios interactúen con los datos de forma transparente.

La fragmentación mejora el rendimiento al acercar los datos al usuario, mientras que la replicación incrementa la disponibilidad. Sin embargo, ambas estrategias implican compromisos en términos de complejidad y costos.

Gestores en el mercado

Gestor	Estrategia de distribución	Modelo de datos	Licencia / Costo
Apache Cassandra	Fragmentación (sharding automático) + Replicación.	No relacional (columnas).	Libre (Open Source).
MongoDB	Fragmentación (sharding) + Replicación.	No relacional (documentos).	Libre (Community) / De pago (Enterprise).
MySQL Cluster	Fragmentación + Replicación.	Relacional.	Libre (Community) / De pago (Enterprise).
PostgreSQL	Fragmentación (particionado) + Replicación.	Relacional.	Libre (Open Source).
Oracle Database	Fragmentación + Replicación.	Relacional.	De pago.
Microsoft SQL Server	Replicación + Fragmentación (particiones).	Relacional.	De pago (con versión Express gratuita).
Apache HBase	Fragmentación + Replicación.	No relacional (columnar).	Libre (Open Source).

Referencias

- Özsu, M. T., & Valduriez, P. (2011).
  Principles of Distributed Database Systems (3rd ed.). Springer.

- Elmasri, R., & Navathe, S.
  Fundamentals of Database Systems.

- PostgreSQL Global Development Group. (s.f.). PostgreSQL Documentation: Replication and Partitioning. https://www.postgresql.org/docs/

- MongoDB Inc.. (s.f.). Replication and Sharding in MongoDB.
  https://www.mongodb.com/docs/

- Apache Software Foundation. (s.f.). Apache Cassandra Documentation.
  https://cassandra.apache.org/doc/

- Microsoft. (s.f.). Distributed Databases and Replication (SQL Server).
  https://learn.microsoft.com/sql/